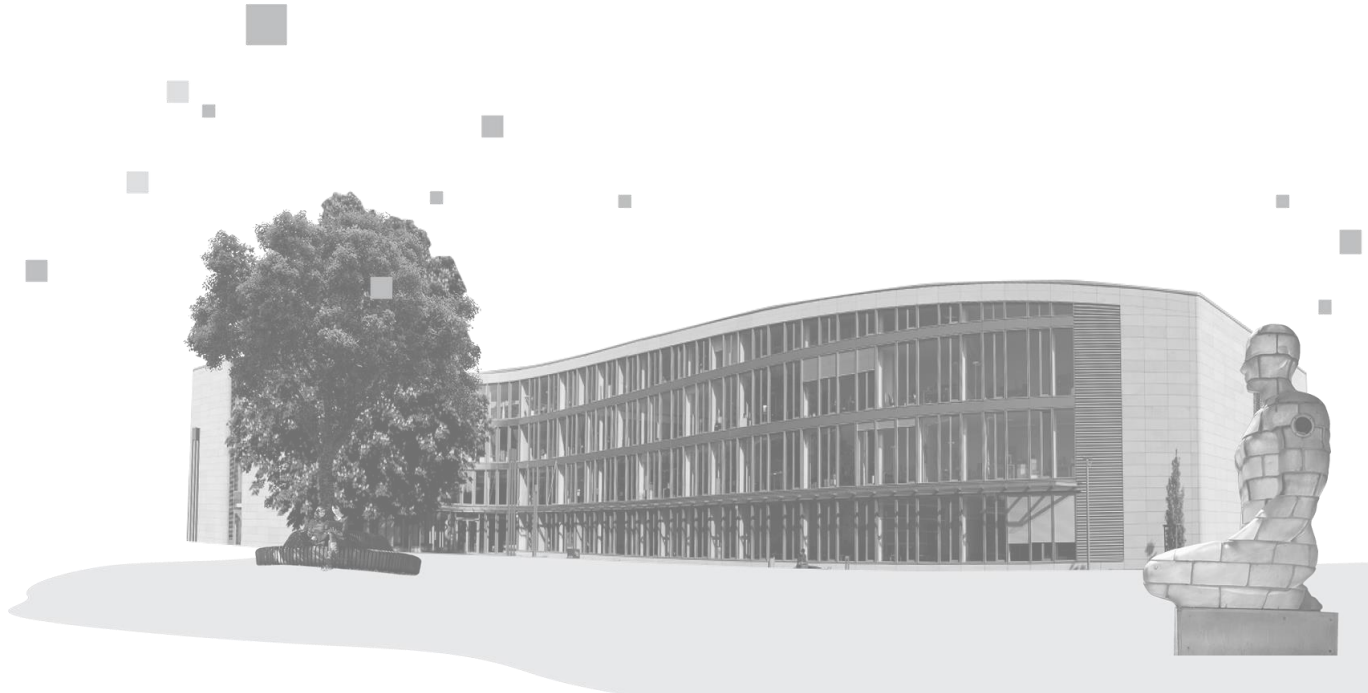
KI Service Zentrum
by Hasso-Plattner-Institut

HPI

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

AI Service Centre Berlin-Brandenburg



Design IT.
Create Knowledge.

www.hpi.de

ERRATE DIE ZAHL

KI Service Zentrum
by Hasso-Plattner-Institut
HPI

Text 1

Administrationskonten sollten durch Mehr-Faktor-Authentisierung geschützt werden, da sie ein besonders hohes Schadenspotenzial besitzen und bevorzugtes Angriffsziel darstellen.

Text 2

Erstellen Sie eine Cloud-Nutzungsstrategie (A1), eine Sicherheitsrichtlinie (A2), Service-Definitionen (A3) und legen Sie Verantwortungsbereiche sowie Schnittstellen fest (A4). Diese vier Basis-Anforderungen müssen vorrangig erfüllt werden.

Text 3

Bei personellen Veränderungen müssen nicht mehr benötigte Benutzendenkennungen und Berechtigungen unverzüglich entfernt werden, um unberechtigte Zugriffe ehemaliger oder versetzter Mitarbeitender zu vermeiden. Es dürfen Berechtigungen nur hinsichtlich des tatsächlichen Bedarfs zur Aufgabenerfüllung vergeben werden.

Gefördert durch:
Bundesministerium
für Forschung, Technologie
und Raumfahrt

Mentimeter-Code: ____

WAS IST EINE AUSSAGE?

KI Service Zentrum by Hasso-Plattner-Institut

Alltag (Wörterbuch)

Eine Aussage ist ein Satz, der etwas feststellt.

Danach ist der Beispielsatz eine Aussage. Man kann auch zwei zählen: Hauptsatz und Nebensatz sind zwei Sätze.

Logik

Eine Aussage ist etwas, das für sich allein wahr oder falsch sein kann.

"A, weil B und C" sind drei Aussagen: A, B, C, und außerdem die Behauptung, dass B und C der Grund für A sind. Danach hat der Beispielsatz drei bis vier Aussagen.

NLP-Forschung (FActScore)

Eine Aussage ist die kleinste Einheit, die eine Information trägt und sich gegen eine Quelle prüfen lässt.

Jedes Element einer Aufzählung zählt. Danach hat der Beispielsatz drei Aussagen.

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

ARBEITSDEFINITION

KI Service Zentrum by Hasso-Plattner-Institut HPI

Eine Aussage ist der kleinste Teil der Referenzantwort, der sich für sich allein gegen das Kompendium prüfen lässt.

1. Jedes Element einer Aufzählung ist eine eigene Aussage.
2. Jede Begründung (weil, da) und jeder Zweck (um zu) ist eine eigene Aussage.
3. Wiederholungen und Füllwörter zählen nicht.

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

BEISPIEL 1: WIE VIELE AUSSAGEN?

Administrationskonten sollten durch Mehr-Faktor-Authentisierung geschützt werden, da sie ein besonders hohes Schadenspotenzial besitzen und bevorzugtes Angriffsziel darstellen.

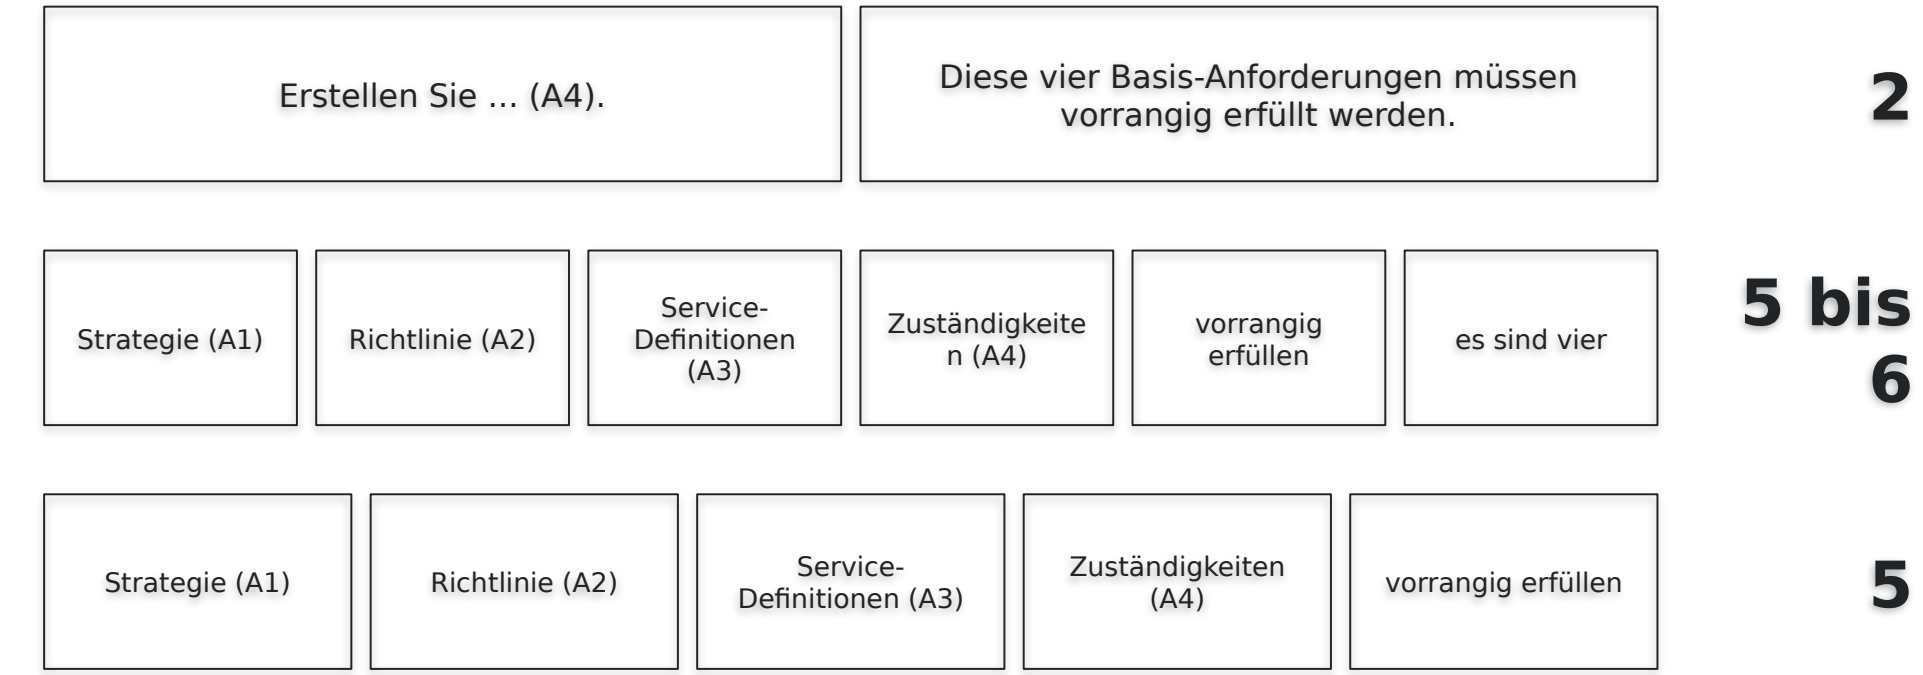
Alltag	Administrationskonten sollten durch MFA geschützt werden, da sie ein hohes Schadenspotenzial besitzen und bevorzugtes Angriffsziel darstellen.	**1 (oder 2)**
Logik	Adminkonten sollten durch MFA geschützt werden sie besitzen ein hohes Schadenspotenzial sie sind bevorzugtes Angriffsziel weil: das ist der Grund	**3 bis 4**
Arbeitsdefinition	Adminkonten sollten durch MFA geschützt werden Grund: hohes Schadenspotenzial Grund: bevorzugtes Angriffsziel	**3**

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

BEISPIEL 2: WIE VIELE AUSSAGEN?

Erstellen Sie eine Cloud-Nutzungsstrategie (A1), eine Sicherheitsrichtlinie (A2), Service-Definitionen (A3) und legen Sie Verantwortungsbereiche sowie Schnittstellen fest (A4). Diese vier Basis-Anforderungen müssen vorrangig erfüllt werden.



Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

BEISPIEL 3: WIE VIELE AUSSAGEN?

KI Service Zentrum by Hasso-Plattner-Institut HPI

Bei personellen Veränderungen müssen nicht mehr benötigte Benutzendenkennungen und Berechtigungen unverzüglich entfernt werden, um unberechtigte Zugriffe ehemaliger oder versetzter Mitarbeitender zu vermeiden. Es dürfen Berechtigungen nur hinsichtlich des tatsächlichen Bedarfs zur Aufgabenerfüllung vergeben werden.

Alltag	Bei personellen Veränderungen ... zu vermeiden. / Es dürfen Berechtigungen nur ... vergeben werden.	**2**
Logik	Kennungen entfernen / Berechtigungen entfernen / unverzüglich / Zweck: unberechtigte Zugriffe vermeiden / Berechtigungen nur nach Bedarf	**4 bis 5**
Arbeitsdefinition	Kennungen und Berechtigungen entfernen / unverzüglich / Zweck: unberechtigte Zugriffe vermeiden / Berechtigungen nur nach Bedarf	**4**

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

ERRATE DIE ZAHL, RUNDE 2

KI Service Zentrum
by Hasso-Plattner-Institut
HPI

Eine Aussage ist der kleinste Teil der Referenzantwort, der sich für sich allein gegen das Kompendium prüfen lässt.

Text 1

Administrationskonten sollten durch Mehr-Faktor-Authentisierung geschützt werden, da sie ein besonders hohes Schadenspotenzial besitzen und bevorzugtes Angriffsziel darstellen.

Text 2

Erstellen Sie eine Cloud-Nutzungsstrategie (A1), eine Sicherheitsrichtlinie (A2), Service-Definitionen (A3) und legen Sie Verantwortungsbereiche sowie Schnittstellen fest (A4). Diese vier Basis-Anforderungen müssen vorrangig erfüllt werden.

Text 3

Bei personellen Veränderungen müssen nicht mehr benötigte Benutzendenkennungen und Berechtigungen unverzüglich entfernt werden, um unberechtigte Zugriffe ehemaliger oder versetzter Mitarbeitender zu vermeiden. Es dürfen Berechtigungen nur hinsichtlich des tatsächlichen Bedarfs zur Aufgabenerfüllung vergeben werden.

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

Mentimeter-Code: ____

WAS RAGAS DEM RICHTER SAGT

KI Service Zentrum by Hasso-Plattner-Institut

Die Anweisung an den Richter, wörtlich:

> Given a context, and an answer, analyze each statement in the answer and classify if the statement can be attributed to the given context or not.

Keine Definition. Der Richter entscheidet selbst, was eine Aussage ist.

> Unternehmen können sich für Pilotprojekte bewerben und erhalten 2-3 Tage pro Woche aktive Projektbegleitung, um gemeinsam einen Prototypen zu entwickeln. Dabei können sie auch die Recheninfrastruktur nutzen.

gpt-oss-120b

2 Aussagen

zerlegt meist je Satz

llama-3-3-70b

4 Aussagen

zerlegt feiner

Dieselbe Referenzantwort aus Notebook 2, Abschnitt E b. Der Nenner von Context Recall hängt davon ab, wer zerlegt.

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

RESEARCH

- **AI Methods Research**
- **AI Operations Research**



PubMedCLIP: How Much Does CLIP Benefit Visual Question Answering in the Medical Domain?

Sedigheh Eslami, Christoph Meinel, Gerard de Melo

Hasso Plattner Institu

{sedigheh.eslami, christoph

Abstract

Contrastive Language–Image Pre-training (CLIP) has shown remarkable success in learning with cross-modal supervision from extensive amounts of image–text pairs collected online. Thus far, the effectiveness of CLIP has been investigated primarily in general-domain multimodal problems. In this work, we evaluate the effectiveness of CLIP for the task of Medical Visual Question Answering (MedVQA). We present PubMedCLIP, a fine-tuned version of CLIP for the medical domain based on PubMed articles. Our experiments conducted on two MedVQA benchmark datasets illustrate that PubMedCLIP achieves superior results improving the overall accuracy up to 3% in comparison to the state-of-the-art Model-Agnostic Meta-Learning (MAML) networks pre-trained only on visual data. The PubMedCLIP model with different back-ends, the source code for pre-training them and reproducing our MedVQA pipeline is publicly available at https://github.com/sarahESL/PubMedCLIP.

1 Introduction

Medical visual question answering (MedVQA seeks answers to natural language questions abou a given medical image. The development of Med VQA has considerable potential to benefit health care systems, as it may aid clinicians in interpreting medical images and obtaining more accurate diag noses by consulting a second opinion. Thus, it has become a very active area of research, with compet itive benchmarks and yearly competitions (Abacha et al., 2021). Yet, visual question answering in the medical domain in particular remains non-trivial as we suffer from a general lack of large balanced training data, in part due to privacy concerns. To solve the multimodal task of MedVQA, a system must understand both medical images and textua questions and infer the associations between them sufficiently well to produce a correct answer (An

Findings of the Association for Computati
May 2-6, 2023 ©2023 Associ

Exploring Paracrawl for Document-level Neural Machine Translation

Yusser Al Ghussin[1,2], Jingyi Zhang[3] and Josef van Genabith[1,2]
[1]German Research Center for Artificial Intelligence (DFKI),
Saarland Informatics Campus, Saarbrucken, Germany
[2]Department of Language Science and Technology, Saarland University, Germany
[3]Hasso-Plattner-Institut (HPI), Potsdam, Germany
yusser.al_ghussin/Josef.Van_Genabith@dfki.de,Jingyi.Zhang@hpi.de

Abstract

Document-level neural machine translation (NMT) has outperformed sentence-level NMT on a number of datasets. However, document-level NMT is still not widely adopted in real-world translation systems mainly due to the lack of large-scale general-domain training data for document-level NMT. We examine the effectiveness of using Paracrawl for learning document-level translation. Paracrawl is a large-scale parallel corpus crawled from the Internet and contains data from various domains. The official Paracrawl corpus was released as parallel sentences (extracted from parallel webpages) and therefore previous works only used Paracrawl for learning sentence-level translation. In this work, we extract parallel paragraphs from Paracrawl parallel webpages using automatic sentence alignments and we use the extracted parallel paragraphs as parallel documents for training document-level translation models. We show that document-level NMT models trained with only parallel paragraphs from Paracrawl can be used to translate real documents from TED, News and Europarl, outperforming sentence-level NMT models. We also perform a targeted pronoun evaluation and show that document-level models trained with Paracrawl data can help context-aware pronoun translation. We release our data and code here[1].

1 Introduction

The Transformer translation model (Vaswani et al., 2017), which performs sentence-level translation based on attention networks, has achieved great success and significantly improved the state-of-the-art in machine translation. Compared to sentence-level translation, document-level translation (Xu et al., 2021; Bao et al., 2021; Jauregi Unanue et al., 2020; Ma et al., 2020; Maruf et al., 2019; Tu et al., 2018; Maruf and Haffari, 2018) performs translation at document-level and can potentially fur-

[1]https://github.com/Yusser96/Exploring-Paracrawl-for-Document-level-Neural-Machine-Translation

Proceedings of the 17th Conference of the European Chapter o
May 2-6, 2023 ©2023 Associa

Efficient Parallelization Layouts for Large-Scale Distributed Model Training

Johannes Hagemann
Aleph Alpha / Hasso Plattner Institute
johannes.hagemann@student.hpi.de

Samuel Weinbach
Aleph Alpha
samuel.weinbach@aleph-alpha.com

Konstantin Dobler
Hasso Plattner Institute
konstantin.dobler@hpi.de

Maximilian Schall
Hasso Plattner Institute
maximilian.schall@hpi.de

Gerard de Melo
Hasso Plattner Institute
gerard.demelo@hpi.de

Abstract

Efficiently training large language models requires parallelizing across hundreds of hardware accelerators and invoking various compute and memory optimizations. When combined, many of these strategies have complex interactions regarding the final training efficiency. Prior work tackling this problem did not have access to the latest set of optimizations, such as FLASHATTENTION or sequence parallelism. In this work, we conduct a comprehensive ablation study of possible training configurations for large language models. We distill this large study into several key recommendations for the most efficient training. For instance, we find that using a micro-batch size of 1 usually enables the most efficient training layouts. Larger micro-batch sizes necessitate activation checkpointing or higher degrees of model parallelism and also lead to larger pipeline bubbles. Our most efficient configurations enable us to achieve state-of-the-art training efficiency results over a range of model sizes, most notably a Model FLOPs utilization of 70.5% when training a LLAMA 13B model.

1 Introduction

The number of parameters and computational resources spent on training deep neural networks is growing rapidly [1, 3, 14]. The largest models consisting of hundreds of billions of parameters do not even fit onto a single hardware accelerator. Thus, training these models requires various ways of reducing the memory requirements, such as ZeRO [16], activation checkpointing [2], and 3D-parallel (data, tensor, and pipeline parallel) training [13]. 3D parallelism, in particular, has been demonstrated to be effective for the training of Transformer-based large language models (LLMs) with hundreds of billions of parameters [13].

However, training these models efficiently with 3D parallelism requires significant domain expertise and extensive manual effort to determine the ideal configurations. These configurations not only need to combine data, model, and pipeline parallelism most efficiently, but also consider complex interactions with other memory and compute optimizations. FLASHATTENTION [5] in particular has had a notable impact since its release, enabling us to train models at previously impossible degrees of training efficiency. In light of these developments, we conduct a systematic study via a large-scale training efficiency sweep of these interactions. We consider up to 256 GPUs and LLAMA models with up to 65 billion parameters.

Workshop on Advancing Neural Network Training at 37th Conference on Neural Information Processing Systems (WANT@NeurIPS 2023).

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

EDUCATION

Newsletter

Talks

tele-task.de/series/1463

- Guest talks on research and innovation



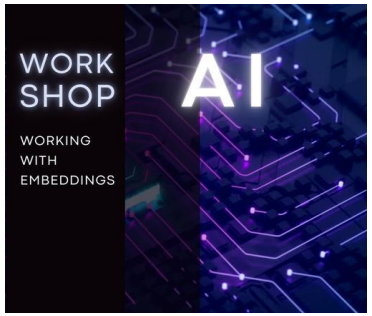




Work shops

aimaker.community

- Practical topics
- Example topics: Speech2summary, Docker for ML, semantic search



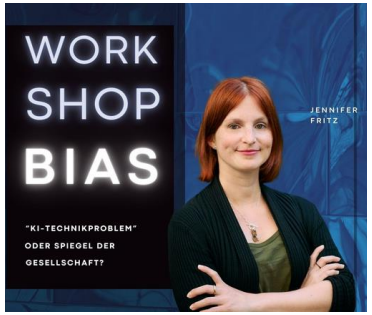


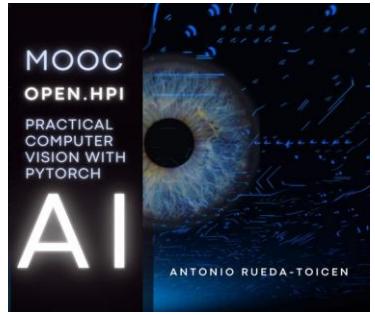


MOOCs

open.hpi.de/channels/ai-service-center

- ChatGPT: What does generative AI mean for our society?
- Profitable AI
- Understanding and avoiding AI biases







Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

INFRASTRUCTURE

KI Service Zentrum by Hasso-Plattner-Institut HPI

aisc.hpi.de





- Access **free of charge**
- No production operation
  - Data should be **anonymised** or **synthesised**
  - No **hosting of products**
- **Reporting** & **publication** by users
- **Existing rights** remain with users
- **New rights** remain with users
  - Granting of rights for research and teaching

Training
- 64 NVIDIA H100 GPU

Inference
- 40 NVIDIA A30 GPU

ARM Server
- Ampere Altra Max M128-30 CPU
- 2 x NVIDIA L40 GPUs

GPU Server
- AMD Epyc CPU
- 8 x NVIDIA L40S GPU

Edge
- ARMv8 CPU
- NVIDIA Jetson AGX Module

Neuromorph
- 288 SpiNNaker

Storage
- 1.5 PB NVRAM

Network
- 400 Gb/s Infiniband
- 200 Gb/s Ethernet

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

ADVISORY

Consultation

AI Consultation

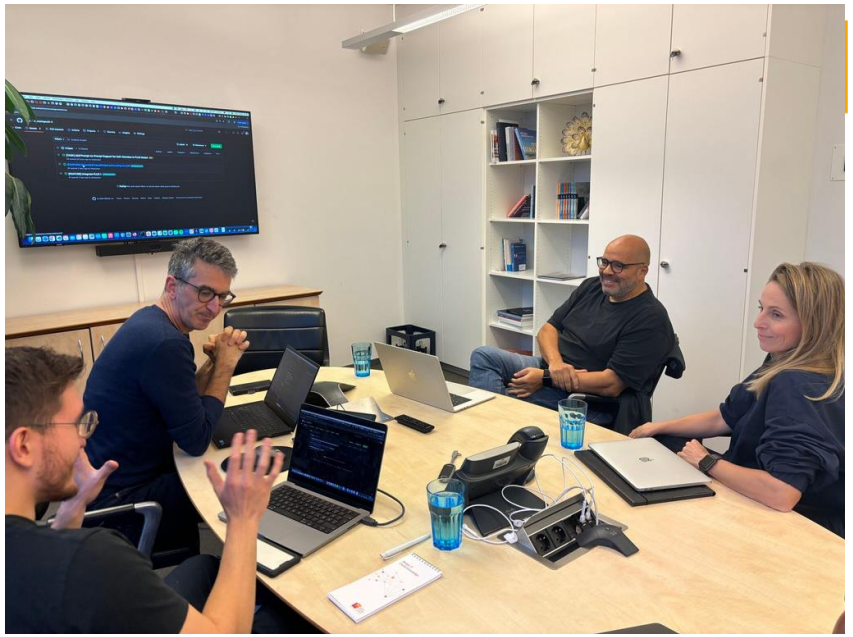
- AI Infrastructure
- AI Models & Frameworks
- AI Use Cases

AI Pilot Projects

- Co-development of a prototype
- Applications every three months
- Selection criteria e.g. AI maturity, common good
- Publication of results

Collaborations

- Organisied community meetings



Previous AI Pilot Projects

- Generation of maths problems
- Generation of plain language
- Generation of upcycling suggestions
- Reduction of food waste
- Dating of handwriting

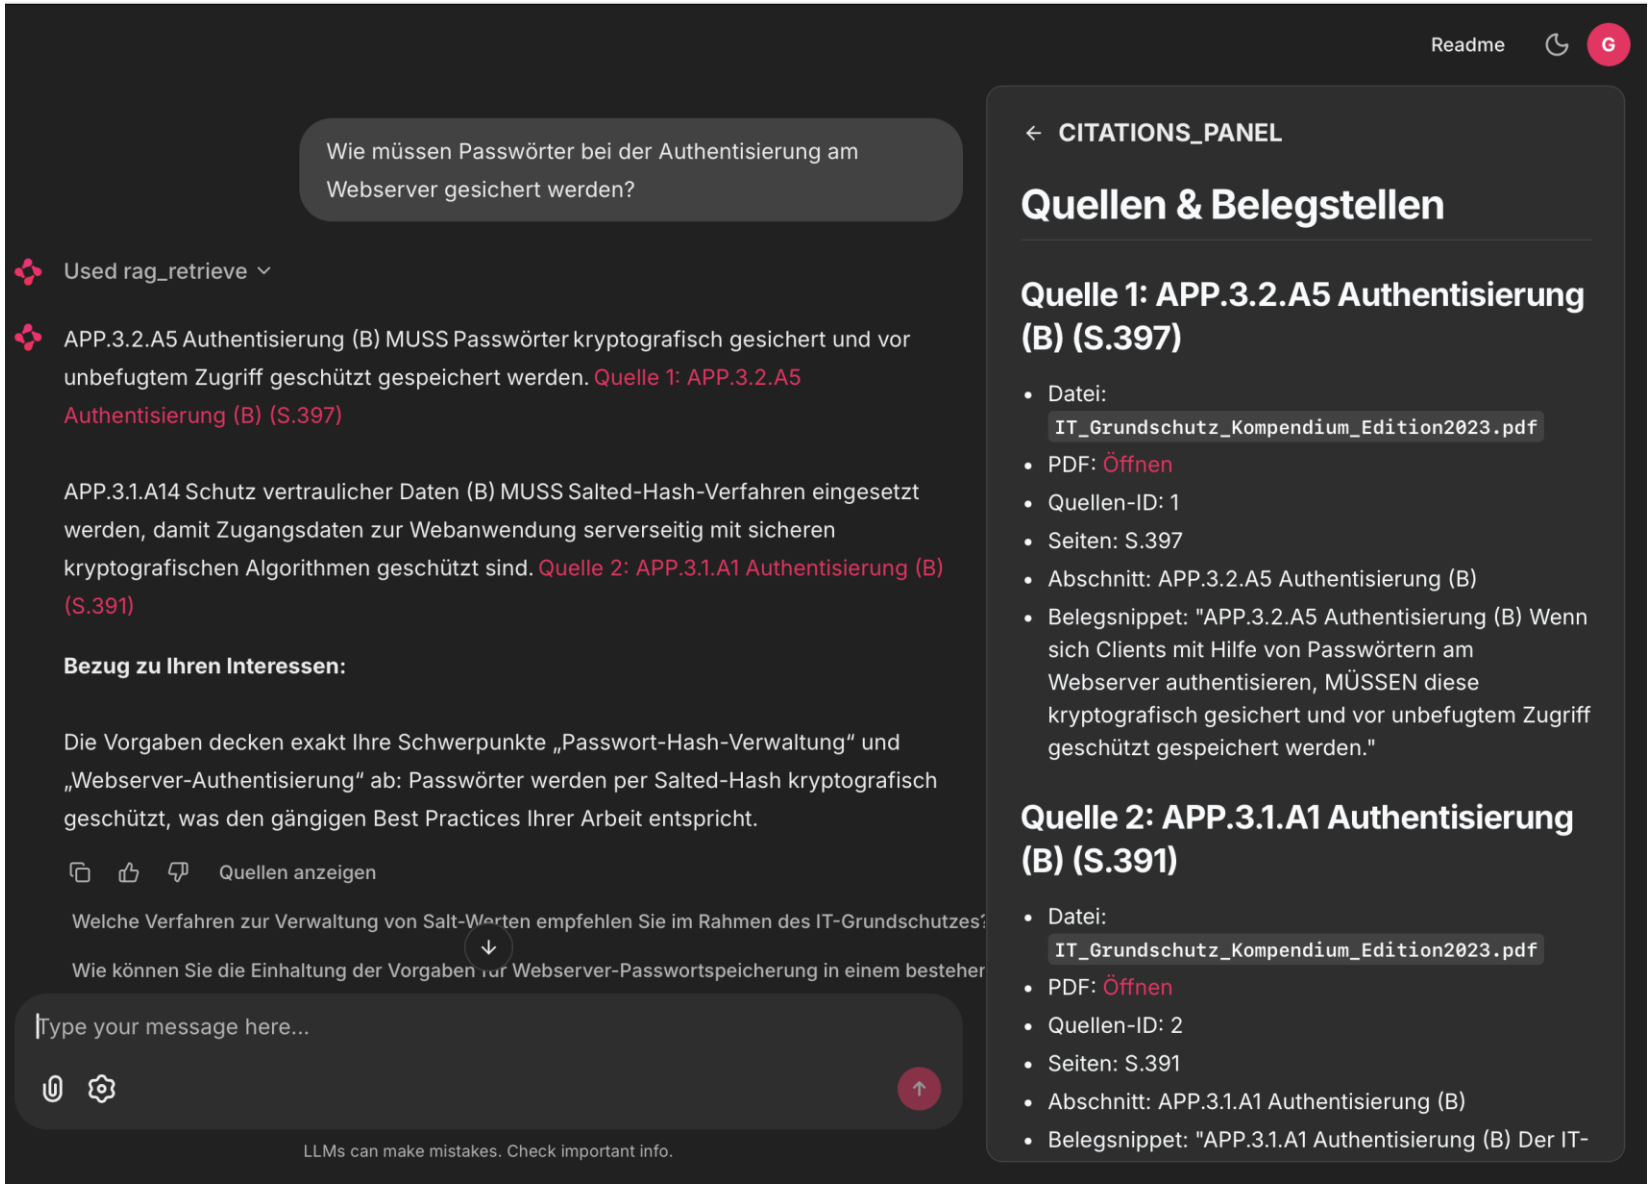
Apply now!

Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

PILOT PROJECT: RAG SYSTEM

KI Service Zentrum by Hasso-Plattner-Institut

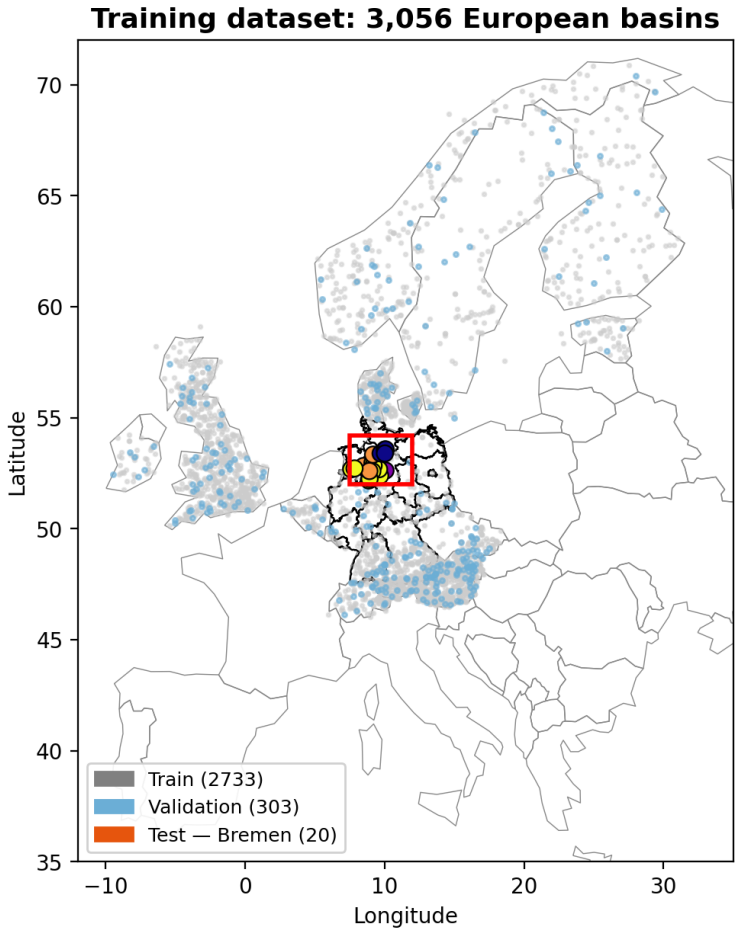


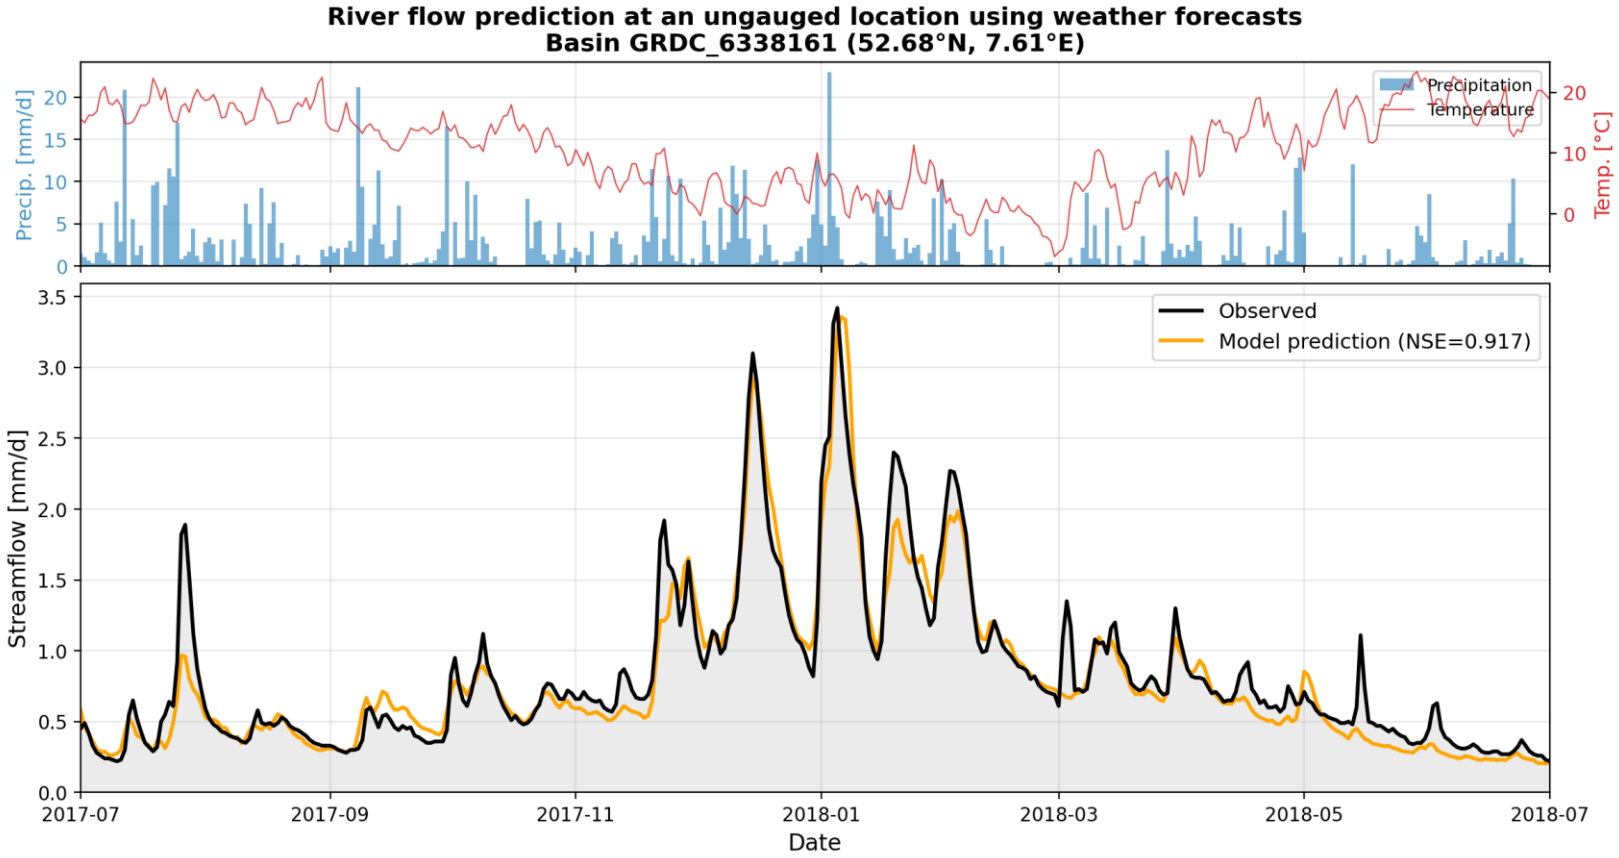
Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

PILOT PROJECT: OPEN RIVER SENSE

KI Service Zentrum by Hasso-Plattner-Institut



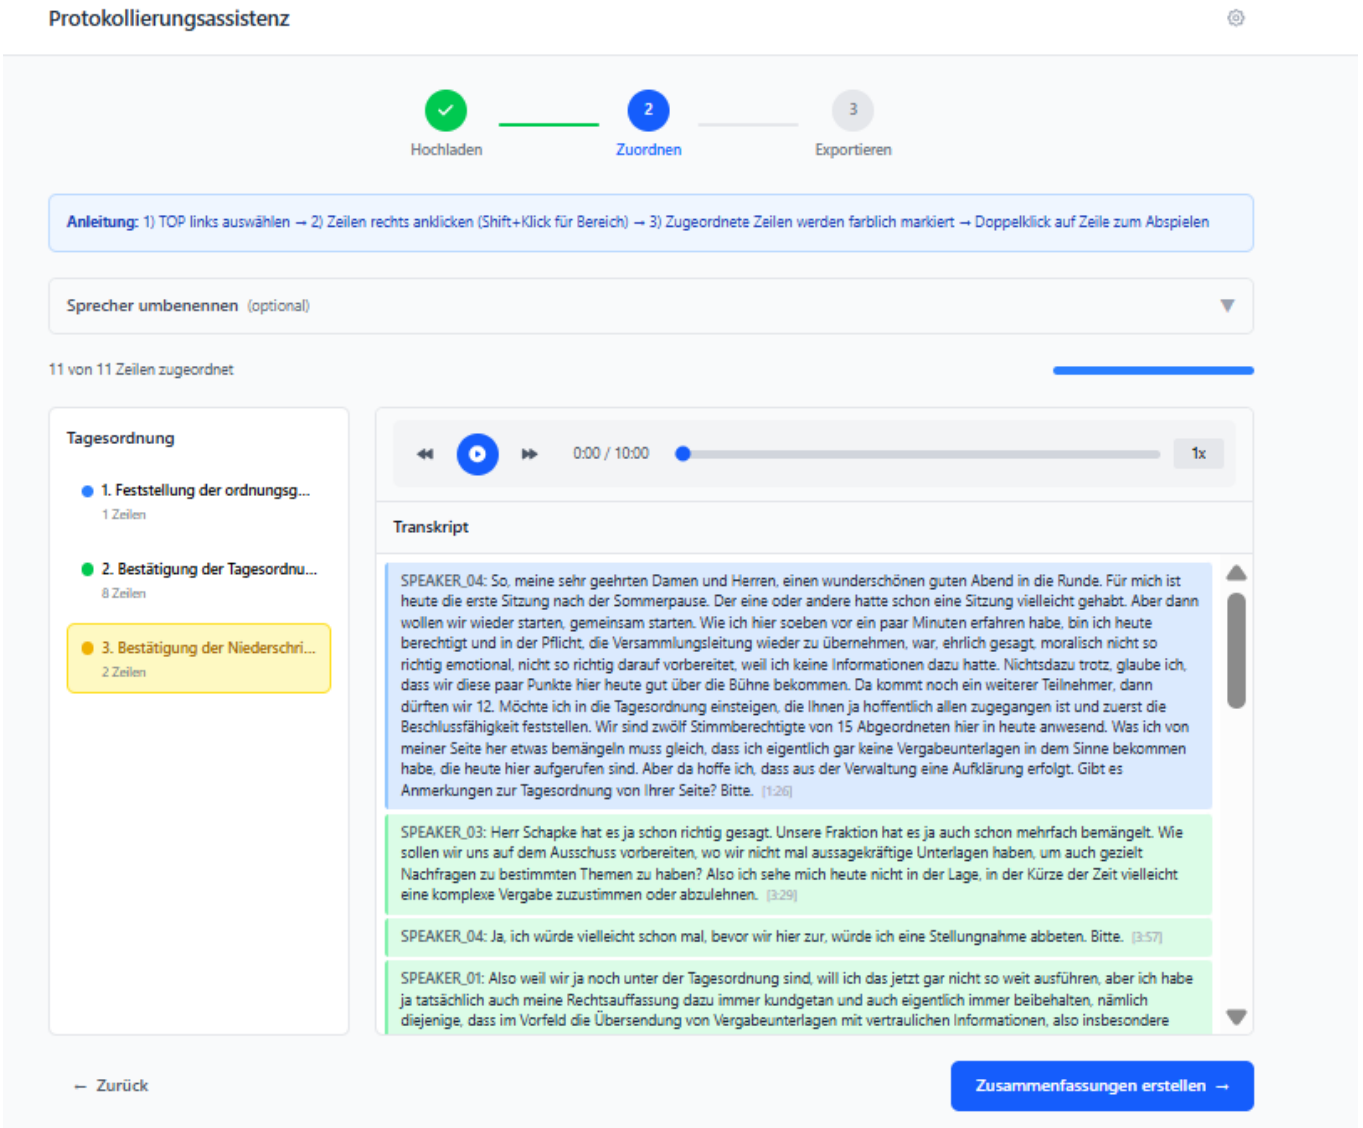


Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

PILOT PROJECT: AUTOMATIC TRANSCRIPTION

KI Service Zentrum by Hasso-Plattner-Institut HPI



Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

PILOT PROJECT: GENERATIVE AI

KI Service Zentrum by Hasso-Plattner-Institut

huggingface.co/datasets/aihpi/fashion-prompt-to-prompt



A cropped jacket with patch pockets, featuring bold tribal prints and tassel closures.

Original Caption

Add a detachable faux fur collar to the neckline for winter wear.

Edit Instruction



A cropped jacket with patch pockets, featuring bold tribal prints and tassel closures, **now includes a detachable faux fur collar at the neckline.**

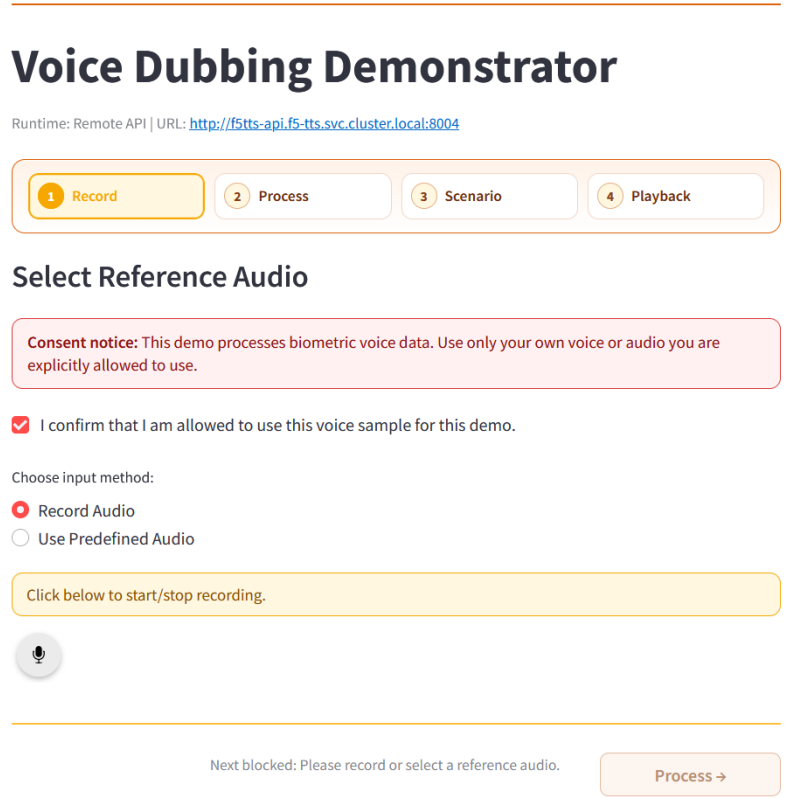
Resulting Caption

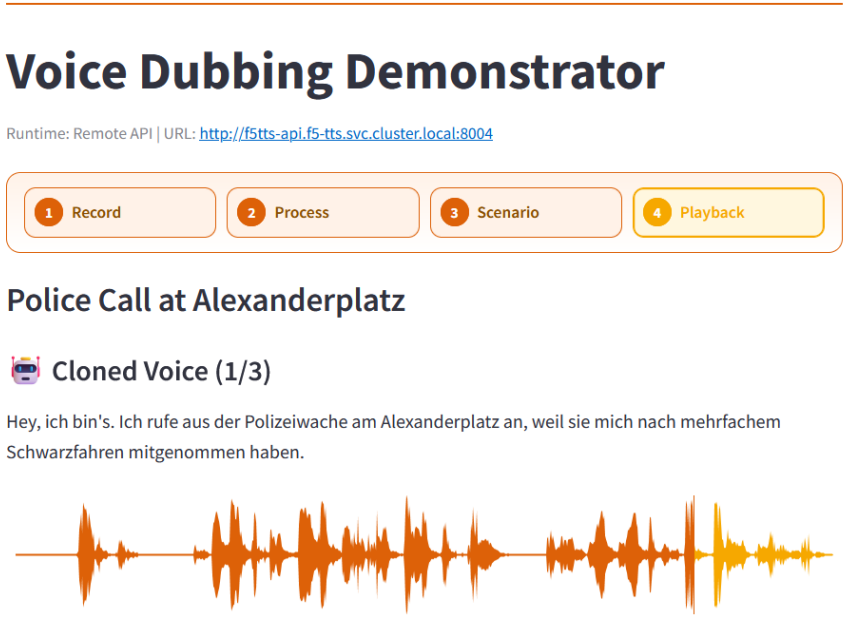
Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

DEMONSTRATOR: VOICE CLONING

https://tts.aisc.hpi.de/
user: event
pw: aisc@hpi2022!

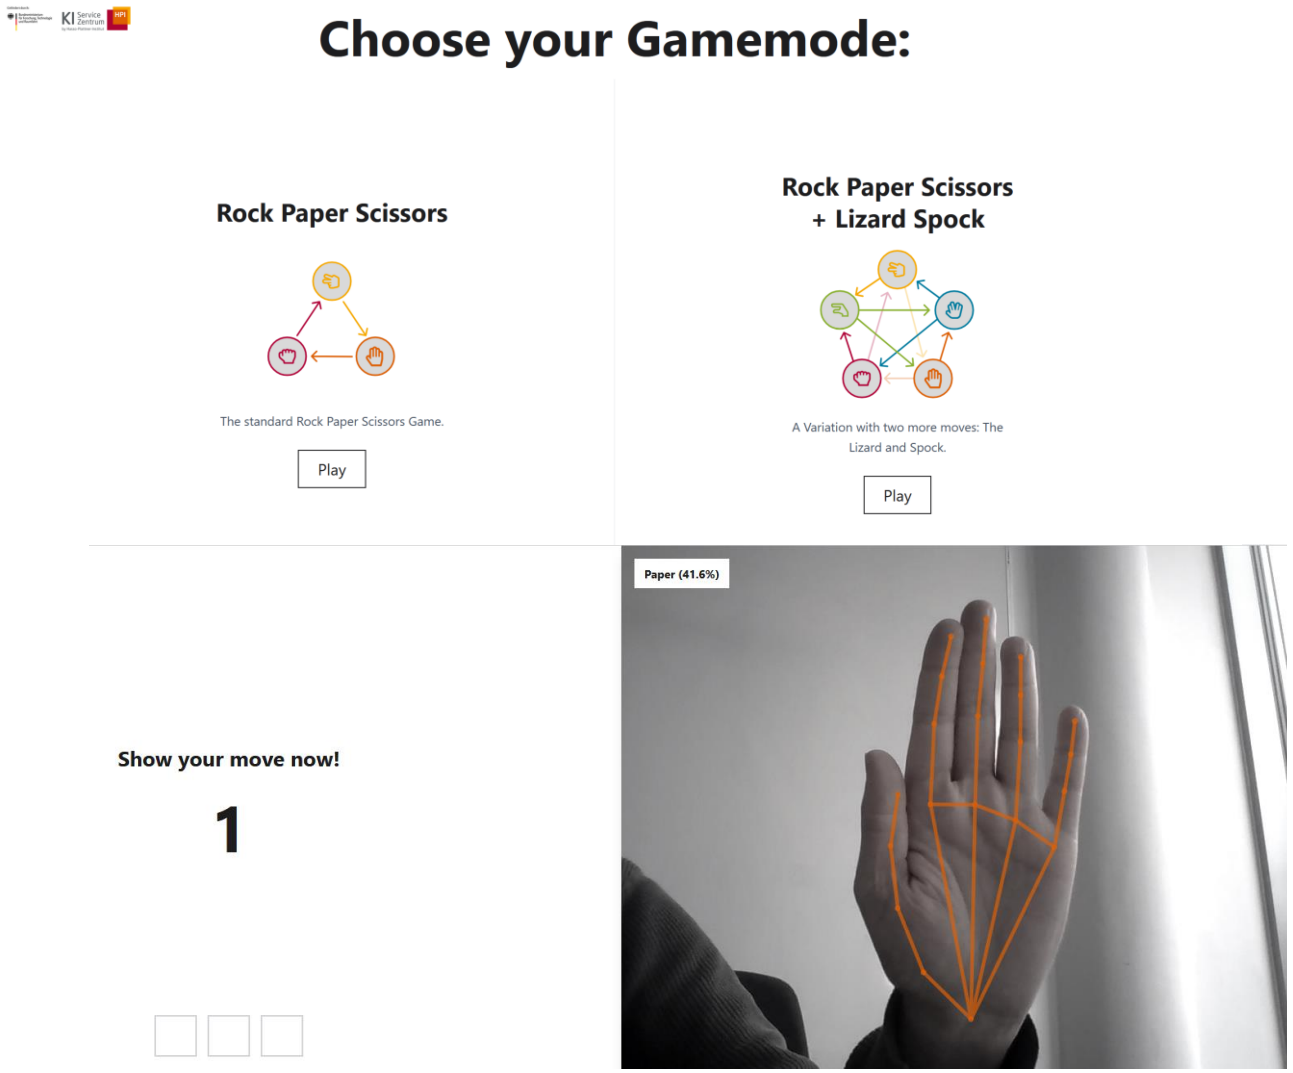




Gefördert durch:
Bundesministerium für Forschung, Technologie und Raumfahrt

DEMONSTRATOR: VISIONARY GESTURES

https://vadimitri.github.io/visionarygestures/

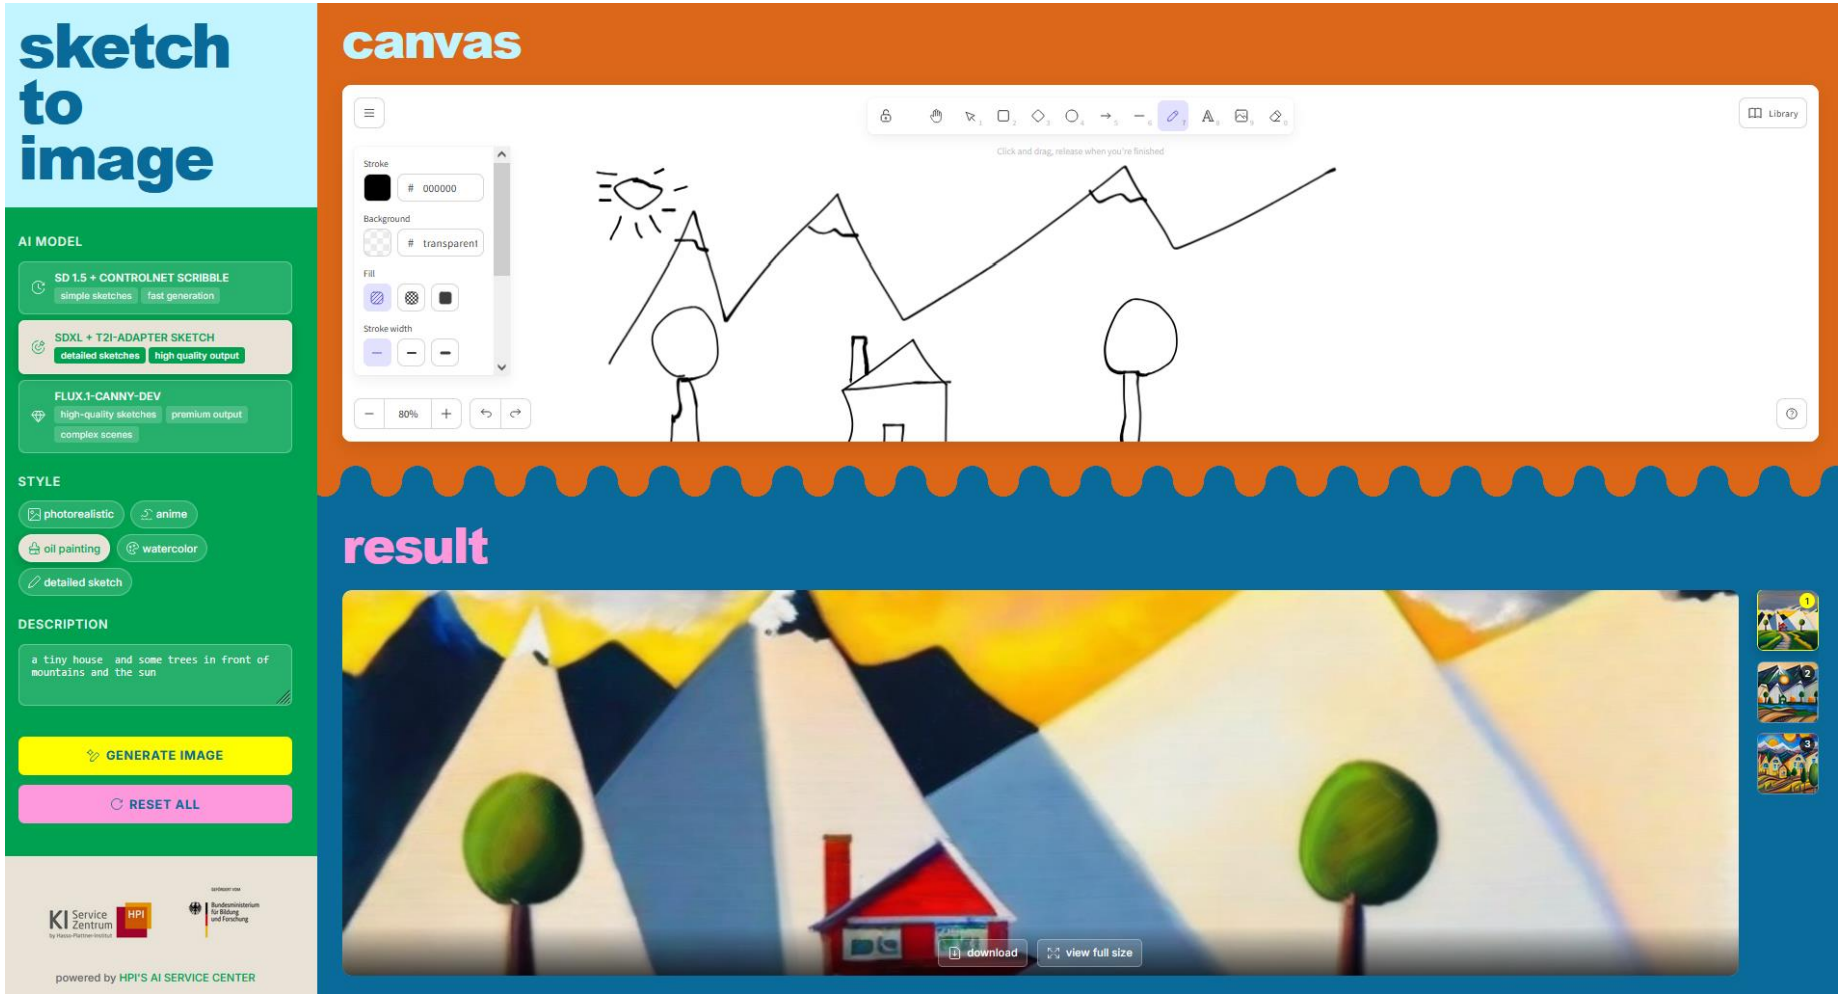


Gefördert durch:

Bundesministerium
für Forschung, Technologie
und Raumfahrt

DEMONSTRATOR: SKETCH2IMAGE

https://s2i.aisc.hpi.de/
user: aisctester
pw: 9OzJ5TzJZybVjm



Gefördert durch:
Bundesministerium für Forschung, Technologie und Raumfahrt

CONTACT US

KI Service Zentrum by Hasso-Plattner-Institut HPI

hpi.de/kisz



HPI

Email:
kisz@hpi.de

Das KI-Servicezentrum Berlin-Brandenburg ist ein Projekt am Hasso-Plattner-Institut. Wir fördern den Einsatz von Künstlicher Intelligenz in Wirtschaft und Gesellschaft.

Wir bieten Beratung, Weiterbildung und Infrastruktur, um KI-Anwendungen eigenständig zu entwickeln, zu betreiben und erfolgreich einzusetzen. Alle unsere Angebote sind kostenlos.

Unsere Angebote:

1. Beratung
2. Weiterbildung
3. Infrastruktur

Virtueller Showroom

Wenn Sie KI eigenständig einsetzen möchten, benötigen Sie Zugang zu Modellen, Codes, Datensätzen und Expertise. All dies bieten wir Ihnen mit den Ergebnissen unserer Forschungs- und Projektarbeit in unserem virtuellen Showroom.

ZUM SHOWROOM

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

kisz@hpi.de
hpi.de/kisz

KI Service Zentrum by Hasso-Plattner-Institut

Gefördert durch:

Bundesministerium für Forschung, Technologie und Raumfahrt

Your feedback is important!

QR-Code for feedback questionaire

